



INSTITUTO FEDERAL
Fluminense
Campus Bom Jesus do Itabapoana

MINISTÉRIO DA
EDUCAÇÃO



**PÁTRIA AMADA
BRASIL**
GOVERNO FEDERAL

Bacharelado em Engenharia de Computação
Ciências do Ambiente

Relatório Final: Previsão do Nível do Rio com Aprendizado de Máquina a partir de
Simulações.

JOÃO VITOR ALMEIDA TEODORO
PEDRO HENRIQUE ROCHA DE ANDRADE
RICARDO DA SILVA DINIZ FILHO

Bom Jesus do Itabapoana, RJ

2025

JOÃO VITOR ALMEIDA TEODORO
PEDRO HENRIQUE ROCHA DE ANDRADE
RICARDO DA SILVA DINIZ FILHO

Relatório Final: Previsão do Nível do Rio com Aprendizado de Máquina a partir de Simulações.

Trabalho realizado durante a disciplina de
Ciências do Ambiente, ministrada pelo
Professor Dr. Carlos Silva Dambroz.

Bom Jesus do Itabapoana - RJ
Março de 2025

Sumário

Sumário.....	2
Resumo.....	3
Introdução.....	4
Fundamentação Teórica.....	5
Objetivos.....	5
Desenvolvimento.....	5
Análise.....	9
Conclusão.....	10

Resumo


Este estudo propõe um modelo de previsão de níveis de rios baseado em Redes Neurais Recorrentes (LSTM) para mitigar os impactos de enchentes em Bom Jesus do Itabapoana (RJ). Utilizando dados simulados de precipitação e nível do rio, o modelo captura padrões temporais complexos por meio de janelas históricas de 24 horas, alcançando um Erro Médio Absoluto (MAE) 7,47 cm. Apesar das limitações impostas pela escassez de dados reais, a abordagem demonstra potencial para aprimorar sistemas de alerta precoce quando integrada a sensores em tempo real. O trabalho destaca a importância da colaboração entre instituições públicas e iniciativas tecnológicas para transformar dados ambientais em ações preventivas, reduzindo riscos socioeconômicos em regiões vulneráveis.

Palavras chaves: Enchentes; Redes Neurais; Precipitação.

Introdução

A crescente frequência de eventos climáticos extremos, evidenciada pelas tragédias no Rio Grande do Sul e em Bom Jesus do Itabapoana, acarreta impactos devastadores tanto na infraestrutura quanto nas finanças, comprometendo significativamente a economia das cidades e o bem-estar da população local.

Figura 1: Simulação 3D da Catástrofe RS.



Fonte: Olhar Digital, 2023.

Diante desse cenário, a utilização de Aprendizado de Máquina para a previsão do nível do rio, fundamentada em dados públicos do INEA, surge como uma alternativa inovadora para antecipar e mitigar os efeitos desses eventos extremos.

A análise integrada desses dados possibilita identificar precocemente padrões anômalos, permitindo respostas mais rápidas e eficazes das autoridades, o que contribui para a redução dos prejuízos financeiros e dos danos sociais. Assim, este trabalho defende que a combinação entre tecnologia e gestão de riscos ambientais é fundamental para transformar a vulnerabilidade em proteção efetiva, promovendo a resiliência das comunidades afetadas.

Este relatório descreve um modelo de previsão de nível de rios usando Redes Neurais Recorrentes (LSTM) para capturar padrões temporais em dados de precipitação. O modelo foi desenvolvido para prever o nível do rio com base em chuvas acumuladas em diferentes janelas temporais (1h, 6h, 24h, etc.), substituindo abordagens anteriores baseadas em *Random Forest*. A LSTM é ideal para séries temporais, pois consegue memorizar dependências de longo prazo, sendo crucial para prever eventos complexos como enchentes.

Fundamentação Teórica

- LSTM (*Long Short-Term Memory*): Tipo de rede neural recorrente projetada para lidar com sequências temporais, evitando o problema de *vanishing gradients*.
- Normalização (*MinMaxScaler*): Técnica para escalonar dados entre 0 e 1, essencial para o desempenho de redes neurais.
- Janelas Temporais: Dados históricos são organizados em sequências (ex: 24 horas) para treinar o modelo a reconhecer padrões ao longo do tempo.
- MAE (Erro Médio Absoluto): Métrica que mede a diferença média entre previsões e valores reais em unidades absolutas (ex: cm).

Objetivos

Este trabalho se propõe a prever o nível do rio com antecedência usando dados temporais de precipitação e variação histórica do nível de acordo com o volume de precipitação, utilizando dados públicos do INEA (órgão responsável no estado do Rio de Janeiro). No entanto, a falta desses dados levou o trabalho a ser realizado com simulações de dados.

Objetivos Específicos:

- Implementar uma rede neural LSTM para modelar dependências temporais.
- Gerar previsões do nível em tempo real com base em entrada automática de fontes confiáveis de previsão do tempo.
- Fornecer margens de erro e confiabilidade da rede neural.

Desenvolvimento

Devido à dificuldade de realização completa do trabalho, foi utilizado uma simulação de dados para a cidade, onde o nível do rio e as chuvas são dados fictícios de um ano, indo de 01/01/2024 a 31/12/2024. Também foi necessário remover a automação da previsão do tempo, para que seja simplificado e possa ser executado, para isso utilizamos uma entrada manual de precipitação do usuário, e damos à ele uma previsão do nível do rio.

O código feito em Python utiliza as seguintes bibliotecas: TensorFlow/Keras, Pandas, Scikit-Learn. E os dados simulados foram criados com base em dados advindos do INEA, considerando a precipitação nas últimas horas (sendo essas janelas temporais de 3 em 3 horas) e o nível do rio, medido em cm.

Figura 2. Bibliotecas Python

```
import pandas as pd
import numpy as np
import tensorflow as tf
from tensorflow.keras.models import Sequential # type: ignore
from tensorflow.keras.layers import LSTM, Dense, Dropout # type: ignore
from sklearn.preprocessing import MinMaxScaler
from sklearn.metrics import mean_absolute_error
```

Fonte: Autoria própria.

Figura 3. Exemplo de dados simulados

DataHora	Chuva_1h	Nivel_Rio	Chuva_4h	Chuva_24h	Chuva_96h	Chuva_30d
2024-01-01 00:00:00	0,94	1,2	0	0	0	0
2024-01-01 01:00:00	6,03	1,3	0	0	0	0
2024-01-01 02:00:00	2,64	1,43	0	0	0	0
2024-01-01 03:00:00	1,83	1,51	11,44	0	0	0
2024-01-01 04:00:00	0,34	1,52	10,84	0	0	0
2024-01-01 05:00:00	0,34	1,53	5,15	0	0	0
2024-01-01 06:00:00	0,12	1,53	2,63	0	0	0
2024-01-01 07:00:00	4,06	1,72	4,86	0	0	0
2024-01-01 08:00:00	1,86	1,81	6,38	0	0	0
2024-01-01 09:00:00	2,49	1,92	8,53	0	0	0
2024-01-01 10:00:00	0,04	1,92	8,45	0	0	0
2024-01-01 11:00:00	7,12	2,26	11,51	0	0	0
2024-01-01 12:00:00	3,63	2,43	13,28	0	0	0
2024-01-01 13:00:00	0,49	2,45	11,28	0	0	0
2024-01-01 14:00:00	0,41	2,45	11,65	0	0	0
2024-01-01 15:00:00	0,41	2,46	4,94	0	0	0
2024-01-01 16:00:00	0,74	2,49	2,05	0	0	0
2024-01-01 17:00:00	1,52	2,55	3,08	0	0	0
2024-01-01 18:00:00	1,16	2,6	3,83	0	0	0
2024-01-01 19:00:00	0,71	2,62	4,13	0	0	0
2024-01-01 20:00:00	1,95	2,7	5,34	0	0	0
2024-01-01 21:00:00	0,31	2,7	4,13	0	0	0
2024-01-01 22:00:00	0,71	2,73	3,68	0	0	0
2024-01-01 23:00:00	0,94	2,76	3,91	40,79	0	0
2024-01-02 00:00:00	1,26	2,81	3,22	41,11	0	0
2024-01-02 01:00:00	3,19	2,95	6,1	38,27	0	0
2024-01-02 02:00:00	0,46	2,96	5,85	36,09	0	0

Fonte: Autoria Própria

O painel a seguir nos mostrou uma fonte de dados que poderia ser utilizada, no entanto, não há dados completos para disponibilidade de utilização em trabalhos.

Seria necessário ter autorização para operar e ainda assim não são dados totalmente relevantes e precisos para o trabalho.

Figura 4. Painel de Controle da ANA.



Fonte: POWER BI. Relatório de Monitoramento Hidrológico. Microsoft, 2023.

Etapas da Construção:

Pré-processamento:

- Criação de Features:
 - Chuva_6h, Chuva_12h, Chuva_24h: Somas acumuladas.
- Variação_Nível: Diferença entre medições consecutivas.
- Normalização: Aplicação de MinMaxScaler.

Criação de Janelas Temporais:

```
def create_sequences(X, y, time_steps=24):
```

Cada amostra de treino é uma matriz 3D: (número_de_amostras, 24, 7) (24 horas × 7 features).

Estrutura da LSTM:

```
model = Sequential([  
    LSTM(64, return_sequences=True, input_shape=(24, 7)),
```



```

Dropout(0.2),
LSTM(32),
Dense(1)
])

```

Treinamento:

- Função de Perda: MAE (Mean Absolute Error).
- Otimizador: Adam.
- Épocas: 50.

A primeira LSTM processa a sequência completa, enquanto a segunda extrai padrões hierárquicos. Ao fim, gera uma margem de erro (MAE) e o nível da previsão com base no aprendizado feito com os dados simulados.

A figura a seguir mostra um resumo das etapas explicadas em código:

Figura 5. Etapas Código.

```

# 6. Separar treino e teste
split = int(0.8 * len(X_seq))
X_train, X_test = X_seq[:split], X_seq[split:]
y_train, y_test = y_seq[:split], y_seq[split:]

# 7. Construir o modelo LSTM
model = Sequential([
    LSTM(64, return_sequences=True, input_shape=(time_steps, len(features))),
    Dropout(0.2),
    LSTM(32),
    Dense(16, activation='relu'),
    Dense(1)
])

model.compile(optimizer='adam', loss='mse')

# 8. Treinar o modelo
history = model.fit(
    X_train,
    y_train,
    epochs=50,
    batch_size=32,
    validation_data=(X_test, y_test),
    verbose=1
)

# 9. Avaliação
y_pred = model.predict(X_test)
y_pred_rescaled = y_scaler.inverse_transform(y_pred)
y_test_rescaled = y_scaler.inverse_transform(y_test)

mae = mean_absolute_error(y_test_rescaled, y_pred_rescaled)
print(f"\nErro Médio Absoluto (MAE): {mae:.2f} cm")

# 10. Entrada manual para previsão (sem vazão)
nivel_atual = df.iloc[-1]["Nivel_Rio"]
print(f"\nNível atual do rio: {nivel_atual:.2f} cm")

chuva_prevista = float(input("Digite a previsão de chuva para a próxima hora (mm): "))

```

Fonte: Autoria Própria.

O acesso ao código e aos dados é realizado através do Github, pelo link: <https://github.com/pedroiff0/precipitacaoiff>.


Análise

Funcionamento da Previsão:

Entrada do Usuário: Apenas a chuva prevista para a próxima hora é necessária. Os demais campos são a saída do código (nível do rio previsto e a margem de erro, que é o resultado do aprendizado de máquina).

- Chuva prevista: 30.0 mm
- Nível do rio previsto: 18.10 cm
- Margem de erro ($\pm$): 7.47 cm

Figura 5. Utilização do código



```
C:\Users\pedro\AppData\Local\Programs\Python
warnings.warn(
1/1 ██████████ 0s 35ms/step

🌧️ Previsão para próxima hora:
☁️ Chuva prevista: 30.0 mm
🌊 Nível do rio previsto: 18.10 cm
📊 Margem de erro (±): 7.47 cm
```

Fonte: Autoria Própria.

- Cálculo Automático:
 - As chuvas acumuladas (6h, 12h, etc.) são estimadas multiplicando a chuva horária pelo intervalo.
 -
- Combinação com Dados Históricos:
 - A última janela de 23 horas é combinada com a nova entrada para formar uma sequência de 24 horas.

Considerações Finais

O trabalho, por enquanto em fases muito iniciais, pode ser observado algumas melhorias, sugestões, e desafios encontrados ao longo, sendo eles:

Desafios:

- Qualidade dos Dados: Valores ausentes ou inconsistências afetam a criação das janelas temporais.
- Complexidade Computacional: *LSTMs* demandam mais recursos que modelos tradicionais (ex: *Random Forest*).
- Disponibilidade de bases de informações sólidas: Encontrar dados que pudessem validar ou servir minimamente para estudos manuais afetaram o desenvolvimento do trabalho devido à baixa disponibilidade.

Melhorias Propostas:

- Hiperparâmetros: Otimizar o número de unidades LSTM, camadas e taxa de *dropout*.
- Melhorias Adicionais: Incluir temperatura, umidade e vazão, obtidas pelos sensores e pluviômetros.
- Deploy: Implementar o modelo em uma API para integração com sistemas de monitoramento.

Conclusão

O modelo de LSTM utilizado demonstra baixa capacidade de prever níveis de rios com base em padrões temporais de chuva, atingindo um MAE de 7.7 cm no conjunto de teste. A margem de erro associada permite alertas pouco confiáveis para ações preventivas contra enchentes. Para produção, recomenda-se:

- Coleta contínua de dados para atualização do modelo.
- Monitoramento em tempo real via integração com sensores diretamente ligados ao Rio Itabapoana.

Com isso, o intuito inicial do trabalho que era de a cidade de Bom Jesus do Itabapoana, juntamente com o Instituto Federal Fluminense Campus Bom Jesus do Itabapoana, pudesse ter uma forma de alertar aos moradores de áreas comuns de cheias nas épocas se seriam ou não afetados, com o nível do rio subindo de acordo com a precipitação. Entretanto, no decorrer do trabalho dificuldades foram encontradas, que impossibilitaram de certa forma o trabalho de ser continuado, com precisão nos dados. A falta de informações disponíveis tornou a base de dados pouco sólida para realização dos testes e posteriormente uma validação com dados aprimorados e reais.

Trata-se de um modelo que pode, e deve, ser melhorado futuramente, visto que a iniciativa auxilia diretamente a região e cidade, trazendo um conforto e alívio para os habitantes que sofrem com tal risco.

Referências Bibliográficas

AGUAS DO CAPARAÓ. Bom Jesus do Itabapoana. Disponível em:

<https://aguasdocaparao.com.br/bom-jesus-do-itabapoana/>. Acesso em: 25 fev. 2025.

ALAGAMENTOS. floodprediction. GitHub, 2023. Disponível em:

<https://github.com/alagamentos/floodprediction>. Acesso em: 25 fev. 2025.

CEMADEN. Inteligência artificial para redução de risco de inundações. Governo do Brasil, 2023. Disponível em:

<https://www.gov.br/cemaden/pt-br/assuntos/noticias-cemaden/inteligencia-artificial-para-reducao-de-risco-de-inundacoes-alagamentos-foi-o-debate-promovido-pelo-cemaden>. Acesso em: 25 fev. 2025.

CORDMAUR. Sentinel1-Flood-Finder. GitHub, 2023. Disponível em:

<https://github.com/cordmaur/Sentinel1-Flood-Finder>. Acesso em: 25 fev. 2025.

ECMWFCode4Earth. ml_flood. GitHub, 2023. Disponível em:

https://github.com/ECMWFCode4Earth/ml_flood. Acesso em: 25 fev. 2025.

GOOGLE. Flood Forecasting Initiative. Google Research, 2023. Disponível em: <https://sites.research.google/floods//0/0/3>. Acesso em: 25 fev. 2025.

HIMANGSHU1086. Flood-Prediction-Unit-Hydrography-and-ML. GitHub, 2023. Disponível em: <https://github.com/Himangshu1086/Flood-Prediction-Unit-Hydrography-and-ML>. Acesso em: 25 fev. 2025.

INEA. Sistema de Alerta de Cheias. Rio de Janeiro, 2023. Disponível em: <http://alertadecheias.inea.rj.gov.br/alertadecheias/214109520.html>. Acesso em: 25 fev. 2025.

JAQUELINE-SOARES. ML4FF-framework. GitHub, 2023. Disponível em: <https://github.com/jacqueline-soar/ML4FF-framework>. Acesso em: 25 fev. 2025.

MANDAL, Amandeep. Flood-Prediction-Model. GitHub, 2023. Disponível em: <https://github.com/amandp13/Flood-Prediction-Model>. Acesso em: 25 fev. 2025.

MARTINS, Vagner C. Análise de dados hidrológicos para previsão de alagamentos. 2017. 120 f. Dissertação (Mestrado em Engenharia) – Pontifícia Universidade Católica do Rio Grande do Sul, Porto Alegre, 2017. Disponível em: https://lsa-pucrs.github.io/documentation/master_thesis/pep-doc-vagner-martins-2017.pdf. Acesso em: 25 fev. 2025.

POWER BI. Relatório de Monitoramento Hidrológico. Microsoft, 2023. Disponível em: <https://app.powerbi.com/view?r=eyJrljoiODNhMzZhZjAtN2U5Mi00OTZILWI2M2EtMDIwMGE0N2QyZjBmliwidCI6ImUwYmI0MDEyLTgxMGItNDY5YS04YjRkLTlTY2N2ZjZDFiYWY4OCJ9>. Acesso em: 25 fev. 2025.

ROBERTO DEBARBA. sistema-acompanhamento-enchentes. GitHub, 2023. Disponível em: <https://github.com/RobertoDebarba/sistema-acompanhamento-enchentes>. Acesso em: 25 fev. 2025.

SNIRH. Série Histórica de Dados Hidrológicos. Ministério do Desenvolvimento Regional, 2023. Disponível em:

<https://www.snirh.gov.br/hidrotelemetria/serieHistorica.aspx#>. Acesso em: 25 fev. 2025.

SNIRH. Dados Hidrológicos em Tempo Real. Ministério do Desenvolvimento Regional, 2023. Disponível em: <https://www.snirh.gov.br/hidrotelemetria/ultimosDados.aspx#>. Acesso em: 25 fev. 2025.

UNIVERSITY OF TEXAS. Brazil Floods Dashboard. Geospatial Innovation Hub, 2023. Disponível em: https://share.gishub.org/brazil_floods/. Acesso em: 25 fev. 2025.

VERCEL. Flood Risk Web. 2023. Disponível em: <https://flood-risk-web.vercel.app/> . Acesso em: 25 fev. 2025.

PEDROIFF0. precipitacaoiff. GitHub, 2024. Disponível em: <https://github.com/pedroiff0/precipitacaoiff>. Acesso em: 11 mar. 2025.

Mapa 3D revela impacto das inundações em Porto Alegre; veja. Olhar Digital. Disponível em: <https://olhardigital.com.br/2024/05/21/pro/mapa-3d-revela-impacto-das-inundacoes-e-m-porto-alegre-veja/>. Acesso em: 11 mar. 2025