

Conteúdos Abordados

– Introdução à Estatística Descritiva:

- * **Objetivo:** Organizar, resumir e descrever as principais características de um conjunto de dados.
- * **População vs. Amostra. Parâmetro vs. Estatística.**

– Medidas de Tendência Central:

- * **Média Aritmética:** Conceito, cálculo (simples, ponderada), sensibilidade a valores extremos.
- * **Mediana:** Conceito (valor central de dados ordenados), cálculo para dados não agrupados e agrupados, robustez a valores extremos.
- * **Moda:** Conceito (valor mais frequente), cálculo para dados não agrupados e agrupados, distribuições unimodais, bimodais, multimodais e amodais.

– Medidas de Dispersão (Variabilidade):

- * **Amplitude Total.**
- * **Variância (Amostral e Populacional):** Conceito (dispersão em torno da média), cálculo e interpretação.
- * **Desvio Padrão (Amostral e Populacional):** Conceito (raiz quadrada da variância, na mesma unidade dos dados), interpretação.
- * **Coefficiente de Variação:** Conceito (medida de dispersão relativa), utilidade para comparar variabilidade de conjuntos de dados com médias diferentes.

– Medidas de Posição (Separatrizes):

- * **Quartis (Q_1, Q_2, Q_3):** Definição (dividem o conjunto de dados ordenados em quatro partes iguais). Q_2 é a mediana.
- * **Cálculo de quartis para dados não agrupados e agrupados.**
- * **Amplitude Interquartílica ($IQR = Q_3 - Q_1$):** Medida de dispersão robusta.
- * **Percentis, Decis.**

– Análise da Forma da Distribuição e Outliers:

- * **Assimetria (Skewness):**
 - Distribuição Simétrica ($Média \approx Mediana \approx Moda$).
 - Assimétrica à Direita (Positiva): $Moda < Mediana < Média$.
 - Assimétrica à Esquerda (Negativa): $Média < Mediana < Moda$.
- * **Coefficientes de Assimetria (Pearson - menção).**
- * **Curtose (Kurtosis):** Conceito (grau de "achatamento" da curva da distribuição - leptocúrtica, mesocúrtica, platicúrtica - menção).
- * **Identificação de Outliers (Valores Atípicos):** Uso da regra do $1,5 \times IQR$.

– **Representações Gráficas e Interpretação:**

- * Tabelas de Frequência (absoluta, relativa, acumulada).
- * **Histograma:** Construção (classes, amplitudes, frequências), interpretação (forma da distribuição, tendência central, dispersão).
- * Gráfico de Barras e de Setores (Pizza) - para variáveis qualitativas.
- * **Diagrama de Ramo-e-Folhas (Stem-and-Leaf Plot):** Construção, preservação dos dados originais, visualização da forma da distribuição.
- * **Boxplot (Diagrama de Caixa):** Construção (baseado nos quartis, mediana, limites para outliers), interpretação (simetria, dispersão, identificação visual de outliers, comparação de distribuições).

– **Análise Crítica de Medidas Estatísticas:**

- * Vantagens e limitações de cada medida de tendência central e dispersão.
- * Sensibilidade a outliers (ex: média vs. mediana).
- * Escolha da medida apropriada conforme a natureza dos dados e o objetivo da análise.
- * Importância de analisar medidas em conjunto, não isoladamente.

Fórmulas, Definições e Conceitos Essenciais

• **Medidas de Tendência Central:**

- **Média Aritmética ($\bar{x}$ ou μ):** Soma de todos os valores dividida pelo número total de valores.

- **Amostral ($\bar{x}$):** Para uma amostra de n observações $x_1, x_2, \dots, x_n$:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{x_1 + x_2 + \dots + x_n}{n}$$

- **Populacional (μ):** Para uma população finita de N observações. (Fórmula análoga).

- **Média Ponderada:** $\bar{x}_p = \frac{\sum_{i=1}^k x_i w_i}{\sum_{i=1}^k w_i}$, onde w_i são os pesos.

- *Interpretação:* Ponto de equilíbrio ou centro de massa da distribuição dos dados. Sensível a valores extremos.

- **Mediana (Md ou Q_2):** Valor que divide o conjunto de dados ordenados em duas partes iguais (50% dos dados abaixo, 50% acima).

- **Dados Não Agrupados (Ordenados):** Posição da Mediana: $P_{Md} = \frac{n+1}{2}$. Se n é ímpar, a mediana é o valor na posição P_{Md} . Se n é par, a mediana é a média dos dois valores centrais cujas posições envolvem P_{Md} .

- **Dados Agrupados (em classes de frequência):**

$$Md = L_{Md} + \left(\frac{\frac{n}{2} - F_{ant}}{f_{Md}} \right) \times h_{Md}$$

Onde: L_{Md} : Limite inferior da classe mediana (classe que contém a observação $n/2$). n : Número total de observações. F_{ant} : Frequência acumulada da classe anterior à classe mediana. f_{Md} : Frequência simples da classe mediana. h_{Md} : Amplitude da classe mediana.

- *Interpretação*: Medida de tendência central robusta, não afetada significativamente por valores extremos.
- **Moda (Mo)**: Valor(es) que ocorre(m) com maior frequência no conjunto de dados.
 - Uma distribuição pode ser amodal (sem moda), unimodal (uma moda), bimodal (duas modas) ou multimodal (várias modas).
 - Para dados agrupados, a classe modal é a de maior frequência. A moda pode ser estimada (ex: Fórmula de Czuber, King, ou ponto médio da classe modal).
 - *Interpretação*: Valor típico ou mais comum. Útil para dados qualitativos e quantitativos.

- **Medidas de Dispersão (Variabilidade):**

- **Amplitude Total (A_T)**: $A_T = X_{max} - X_{min}$. Diferença entre o maior e o menor valor. Simples, mas sensível a outliers.
- **Variância Amostral (s^2)**: Medida da dispersão quadrática média dos dados em torno da média amostral.

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Fórmula alternativa (para cálculo): $s^2 = \frac{1}{n-1} \left[\sum_{i=1}^n x_i^2 - \frac{(\sum_{i=1}^n x_i)^2}{n} \right]$ ou $s^2 = \frac{1}{n-1} [\sum x_i^2 - n\bar{x}^2]$. *Nota*: A variância populacional (σ^2) usa N no denominador. O uso de $n-1$ para s^2 torna-a um estimador não viesado de σ^2 .

- **Desvio Padrão Amostral (s)**: Raiz quadrada positiva da variância amostral.

$$s = \sqrt{s^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Interpretação: Medida da dispersão "típica" ou "média" dos dados em relação à média, na mesma unidade dos dados originais. Um s maior indica maior variabilidade.

- **Coefficiente de Variação (CV)**: Medida de dispersão relativa, útil para comparar a variabilidade de diferentes conjuntos de dados, mesmo que tenham médias ou unidades diferentes. É adimensional.

$$CV = \frac{s}{\bar{x}} \times 100\% \quad (\text{para } \bar{x} > 0)$$

Interpretação: Quanto maior o CV, maior a variabilidade relativa dos dados.

- **Quartis e Identificação de Outliers:**

- **Quartis**: Dividem o conjunto de dados ordenados em quatro partes iguais.

- **Primeiro Quartil (Q_1):** Valor abaixo do qual se encontram 25% dos dados. (Percentil 25).
- **Segundo Quartil (Q_2):** Mediana. Valor abaixo do qual se encontram 50% dos dados. (Percentil 50).
- **Terceiro Quartil (Q_3):** Valor abaixo do qual se encontram 75% dos dados. (Percentil 75).
- **Cálculo (dados não agrupados):** Um método comum para a posição do k -ésimo percentil (P_k) é $P_k = \frac{k(n+1)}{100}$. Q_1 é P_{25} , Q_3 é P_{75} . Interpolar se necessário.
- **Amplitude Interquartílica (IQR - Interquartile Range):** Medida de dispersão dos 50% centrais dos dados. Menos sensível a outliers que a amplitude total.

$$IQR = Q_3 - Q_1$$

- **Identificação de Outliers (Regra do $1,5 \times IQR$):** Um valor é considerado um outlier se estiver abaixo de L_I ou acima de L_S .
 - Limite Inferior: $L_I = Q_1 - 1,5 \times IQR$
 - Limite Superior: $L_S = Q_3 + 1,5 \times IQR$
 - Outliers "extremos" ou "distantes" podem ser identificados usando $3 \times IQR$.

- **Assimetria de Distribuições:**

- **Relação entre Média, Mediana e Moda:**
 - **Simétrica:** Média $\approx$ Mediana $\approx$ Moda.
 - **Assimétrica à Direita (Positiva):** Moda $<$ Mediana $<$ Média. (Cauda mais longa para a direita).
 - **Assimétrica à Esquerda (Negativa):** Média $<$ Mediana $<$ Moda. (Cauda mais longa para a esquerda).
- *Interpretação Visual:* Pode ser observada em histogramas e boxplots.

- **Construção e Interpretação de Gráficos:**

- **Histograma:**
 - **Construção:** Para dados quantitativos contínuos. Eixo horizontal representa classes (intervalos de valores), eixo vertical representa frequência (absoluta ou relativa). Barras são adjacentes.
 - **Interpretação:** Visualiza a forma da distribuição dos dados (simetria, assimetria, modalidade), tendência central e dispersão.
- **Diagrama de Ramo-e-Folhas (Stem-and-Leaf Plot):**
 - **Construção:** Separa cada valor em um "ramo" (geralmente os primeiros dígitos) e uma "folha" (geralmente o último dígito). Ramos são listados verticalmente, folhas horizontalmente.
 - **Interpretação:** Fornece uma visualização da forma da distribuição similar ao histograma, mas retém os valores individuais dos dados.
- **Boxplot (Diagrama de Caixa):**

- **Construção:** Baseia-se em cinco números resumo: Mínimo (não outlier), Q_1 , Mediana (Q_2), Q_3 , Máximo (não outlier). Outliers são plotados individualmente. A caixa central vai de Q_1 a Q_3 (contém o IQR). Uma linha marca a mediana. "Bigodes" (whiskers) se estendem até o mínimo e máximo dentro dos limites L_I e L_S .
- **Interpretação:** Mostra a tendência central (mediana), dispersão (comprimento da caixa e dos bigodes), assimetria (posição da mediana na caixa, comprimento dos bigodes) e identifica outliers. Excelente para comparar distribuições de diferentes grupos.