

Análise de Fila Única

Prof. Fabrício B. Gonçalves

Instituto Federal Fluminense
Campus Bom Jesus do Itabapoana

Agenda



1 Introdução

Agenda



- 1 Introdução
- 2 Fila M/M/1/ ∞ /FIFO

Agenda



- 1 Introdução
- 2 Fila M/M/1/ ∞ /FIFO
- 3 Fila M/M/m/ ∞ /FIFO

Agenda



- 1 Introdução
- 2 Fila M/M/1/ ∞ /FIFO
- 3 Fila M/M/m/ ∞ /FIFO
- 4 Fila M/M/1/B/FIFO

Agenda



- 1 Introdução
- 2 Fila M/M/1/ ∞ /FIFO
- 3 Fila M/M/m/ ∞ /FIFO
- 4 Fila M/M/1/B/FIFO
- 5 Fila M/M/m/B/FIFO

Introdução

Introdução



O modelo de filas mais simples contém apenas uma fila. Esse modelo pode ser usado para analisar recursos individuais em sistemas de computação.

Muitas filas podem ser modeladas como processos de nascimento e morte em que o estado do sistema é representado pelo número de usuários no sistema.

As filas markovianas são filas únicas com a chegada e atendimento pelo processo de Poisson.

Fila M/M/1/∞/FIFO

Fila M/M/1/∞/FIFO



A fila M/M/1 possui um processo de chegada de Poisson, tempo de serviço exponencial e apenas um servidor, com capacidade e população ilimitada.

Ela é modelada como um processo de nascimento e morte em que as taxas se mantêm constantes independentemente do número de usuários:

$$\lambda_n = \lambda, n = 0, 1, 2, \dots, \infty$$

$$\mu_n = \mu, n = 1, 2, \infty$$

Fila M/M/1/∞/FIFO



De acordo com a solução de equilíbrio geral, obtemos do processo de nascimento e morte a expressão geral p_n que expressa todas as probabilidades de equilíbrio em termos de uma única constante p_0 (a probabilidade de a fila estar vazia, ou 0 cliente no sistema):

$$p_n = \left(\frac{\lambda}{\mu} \right)^n p_0, n = 1, 2, \dots, \infty$$

Sendo $\rho = \frac{\lambda}{\mu}$ a taxa de utilização do servidor, e como as condições de estabilidade necessitam de $0 \leq \rho < 1$, garantimos que $p_0 > 0$, então:

$$p_n = \rho^n p_0, n = 1, 2, \dots, \infty$$

Sendo $p_0 = 1 - \rho$, obtemos:

$$p_n = (1 - \rho)\rho^n, n = 0, 1, 2, \dots, \infty$$

Fila M/M/1



Medidas de Desempenho:

- Intensidade de de tráfego:

$$U = \frac{\lambda}{\rho} \text{ Erlangs}$$

Fila M/M/1/∞/FIFO



Continuação:

- Número médio de requisições no sistema:

$$E[n] = \frac{\rho}{1 - \rho}$$

- Probabilidade de ter n ou mais requisições no sistema:

$$P(\geq n \text{ requisições no sistema}) = \rho^n$$

- Tempo médio de resposta para uma requisição:

$$E[s] = \frac{1}{\mu(1 - \rho)}$$

Fila M/M/1/∞/FIFO



Continuação:

- Tempo médio de espera na fila de uma requisição:

$$E[w] = E[s] - \frac{1}{\mu}$$

- Número médio de requisições na fila:

$$E[n_w] = \frac{\rho^2}{1 - \rho}$$

Fila M/M/1/∞/FIFO



Exemplo

Um servidor Web conectado a um roteador recebe em média 600 requisições de páginas HTML por minuto. Ele tem a capacidade de atender, em média, a 80 requisições por segundo. Calcule todas as propriedades de filas referentes a esse servidor.

Fila M/M/1/∞/FIFO



Exercícios

- 1 Uma empresa de streaming percebeu que os usuários enviam, em média, 50 requisições de streaming por segundo ao seu servidor principal. O servidor, por sua vez, consegue atender a uma média de 55 requisições por segundo. Calcule todas as propriedades de filas referentes a esse servidor.
- 2 Uma grande empresa de e-commerce utiliza uma rede de data centers para lidar com transações de clientes. Cada data center recebe, em média, 80 transações por segundo e consegue processar 90 transações por segundo.
- 3 Uma popular plataforma de jogos online observou que seu servidor principal recebe, em média, 120 conexões por minuto de jogadores. Este servidor consegue estabelecer, em média, 130 conexões por minuto.

Fila M/M/m/∞/FIFO

Fila M/M/m/∞/FIFO



Este tipo de fila difere do tipo anterior por possuir um número máximo de m servidores idênticos. Neste caso, quando todos os servidores estão ocupados, as requisições são mantidas em uma única fila para todos os servidores.

A taxa de chegada se mantém constante, mas a taxa de serviço depende do número de requisições que estão no sistema:

$$\lambda_n = \lambda, \quad n = 0, 1, 2, \dots, \infty$$

$$\mu_n = \begin{cases} n\mu, & \text{se } 1 \leq n < m \\ m\mu, & \text{se } n \geq m \end{cases}$$



Fila M/M/m/∞/FIFO

Neste caso, as equações gerais para a probabilidade de n requisições no sistema dependem de os servidores estarem todos ocupados ou não.

Portanto, tem-se uma probabilidade para até $n < m$ requisições presentes nos centros de serviço, ou outra probabilidade para quando o número de requisições é maior do que o número de servidores ($n \geq m$):

$$P_n = \begin{cases} \frac{1}{n!} U^n P_0, & \text{se } 1 \leq n < m \\ \frac{1}{m! m^{n-m}} U^n P_0, & \text{se } n \geq m \end{cases}$$

Sendo $\rho = \frac{\lambda}{m\mu}$ a taxa de utilização dos servidores e a intensidade de tráfego (U) é definida por:

$$U = \frac{\lambda}{\mu} \text{ Erlangs}$$



Fila M/M/m/∞/FIFO

Para $n < m$, todos os n clientes estão sendo atendidos pelos servidores e a taxa de utilização do sistema é U . Isso dá origem à:

$$\frac{1}{n!} U^n P_0$$

Para $n > m$, todos m servidores estão ocupadas e há $n - m$ clientes na fila. A taxa de utilização do sistema é U , mas ajustada pelo número de servidores m e o número de clientes na fila. Isso dá origem à:

$$\frac{1}{m! m^{n-m}} U^n P_0$$

Fila M/M/m/∞/FIFO



A probabilidade de não existir nenhuma requisição no sistema P_0 é calculada por:

$$P_0 = \left(\frac{U^m}{m!(1-\rho)} + \sum_{n=0}^{m-1} \frac{U^n}{n!} \right)^{-1}$$

- $\frac{U^m}{m!(1-\rho)}$: calcula a probabilidade de haver m ou mais clientes no sistema. Quando o sistema tem m clientes, todos os servidores estão ocupados. O denominador $1-\rho$ ajusta a probabilidade para o caso em que os servidores estão totalmente utilizados.
- $\sum_{n=0}^{m-1} \frac{U^n}{n!}$: é a soma das probabilidade de ter n clientes no sistema, para n entre 0 e $m-1$ (quando todos os servidores estão ocupados, mas não há clientes esperando na fila). A expressão $\frac{U^n}{n!}$ calcula a probabilidade de ter exatamente n clientes no sistema, usando a taxa de utilização U .
- o inverso a soma $(\dots)^{-1}$ é utilizado para calcular a probabilidade P_0 , pois a soma das probabilidades representa as situações em que há clientes no sistema, e queremos encontrar a probabilidade de o sistema estar vazio.

Fila M/M/m/∞/FIFO



A probabilidade de todos os servidores estarem ocupados é definida por:

$$P[\text{fila}] = C(m, \rho) = \left(\frac{U^m}{m!(1-\rho)} + \sum_{n=0}^{m-1} \frac{U^n}{n!} \right)^{-1} \frac{U^m}{m!(1-\rho)} = P_0 \frac{U^m}{m!(1-\rho)}$$

- $C(m, \rho)$: é a probabilidade de que um cliente que chega ao sistema tenha que esperar antes de ser atendido;
- P_0 : é a probabilidade de que não haja clientes no sistema, ou seja, o sistema está vazio;
- $\frac{U^m}{m!(1-\rho)}$: calcula a probabilidade de haver m ou mais clientes no sistema. Quando o sistema tem m clientes, todos os servidores estão ocupados. O denominador $1-\rho$ ajusta a probabilidade para o caso em que os servidores estão totalmente utilizados.

Fila M/M/m/∞/FIFO



Medidas de Desempenho:

- Número médio de requisições em espera:

$$E[n_w] = \frac{\rho}{1 - \rho} C(m, \rho)$$

- Número médio de requisições em atendimento:

$$E[n_s] = U$$

- Número de requisições no sistema:

$$E[n] = E[n_w] + E[n_s]$$

Fila M/M/m/∞/FIFO



Continuação:

- Tempo médio de resposta:

$$E[s] = \frac{E[n]}{\lambda}$$

- Tempo médio de espera na fila:

$$E[w] = \frac{E[n_w]}{\lambda}$$



Fila M/M/m/∞/FIFO

Exemplo

Você é um engenheiro de computação responsável por gerenciar os recursos de um servidor de uma aplicação web. O servidor em questão é utilizado para processar requisições de usuários que buscam acessar uma página da web.

Dados:

- Número de CPUs (m): 5;
- Taxa de Chegada de Requisições (λ): 20 requisições por segundo;
- Taxa de Serviço (μ): 5 requisições por segundo.

Calcule:

- Taxa de utilização por servidor (ρ);
- Intensidade de tráfego (U);
- Probabilidade de nenhuma requisição no sistema (P_0);
- Probabilidade de todas as CPUs estarem ocupadas ($C(m, \rho)$);
- Número de requisições no sistema ($E[n]$);
- Número médio de requisições em espera ($E[n_w]$);



Fila M/M/m/∞/FIFO

Exemplo

Continuação:

- Número médio de requisições em atendimento ($E[n_s]$);
- Número de requisições no sistema ($E[n]$);
- Tempo médio de resposta ($E[s]$);
- Tempo médio de espera na fila ($E[w]$).

Com base nos resultados obtidos, faça um comentário sobre o desempenho do servidor, indicando se ele é capaz de atender às requisições de forma eficiente e quais ajustes, se necessários, poderiam ser feitos para melhorar o desempenho.



Fila M/M/m/∞/FIFO

Exercícios

- 1 Considere um servidor web com 3 sub-servidores idênticos ($m = 3$). As requisições chegam ao sistema com uma taxa média de 6 requisições por minuto ($\lambda = 6$), e cada sub-servidor pode atender uma requisição em 2 minutos em média ($\mu = 0.5$). Calcule os itens pedidos no exemplo.
- 2 Um cluster de computadores possui 4 máquinas idênticas ($m = 4$) para processar jobs que chegam em uma taxa de 8 jobs por segundo ($\lambda = 8$), e cada máquina pode processar um job em 0.1 segundos em média ($\mu = 10$). Calcule os itens pedidos no exemplo.
- 3 Um sistema de banco de dados com 2 réplicas idênticas ($m = 2$) recebe transações em uma taxa média de 5 transações por minuto ($\lambda = 5$), e cada réplica pode processar uma transação em 1 minuto em média ($\mu = 1$). Calcule os itens pedidos no exemplo.

Fila M/M/1/B/FIFO

Fila M/M/1/B/FIFO



Neste tipo sistema, a chegada de requisições é limitada por uma capacidade fixa do sistema.

O sistema pode suportar até B requisições (incluindo a requisição que está em atendimento), e toda nova requisição que chegar enquanto o sistema está com B requisições dentro (na fila e servidor) será descartada, isto é, a entrada será recusada e a requisição partirá sem ter obtido serviço.

Este tipo de sistema é chamado de sistema com perdas.

Fila M/M/1/B/FIFO



A taxa de serviço é constante e a taxa de chegadas depende do número de requisições já recebidas e sendo processadas ou na fila:

$$\lambda_n = \begin{cases} \lambda, & \text{se } n < B \\ 0, & \text{se } n \geq B \end{cases}$$

$$\mu_n = \mu, \text{ se } n = 1, 2, 3, \dots, B$$

Fila M/M/1/B/FIFO



As probabilidades de n usuários no sistema se dão por:

$$P_n = \begin{cases} \frac{1-\rho}{1-\rho^{B+1}} \rho^n, & \text{se } 0 \leq n \leq B \\ 0, & \text{se } n > B \end{cases}$$

Para $n = 0$, significa que não há clientes no sistema. A probabilidade do sistema estar vazio é P_0 .

Para $0 < n < B$, considera a probabilidade de haver n clientes no sistema, que é P_n .

Para $n = B$, o sistema está completamente cheio. A probabilidade do sistema estar completamente cheio é P_B .

Fila M/M/1/B/FIFO



Sendo $\rho = \frac{\lambda}{\mu}$, a taxa de utilização do servidor, a taxa de utilização do sistema (U) se dá por:

$$U = \rho(1 - P_B)$$

Multiplica-se ρ por $1 - P_B$ para ajustar a taxa de utilização pela probabilidade de o sistema estar cheio, proporcionando uma medida mais precisa da taxa de utilização efetiva do servidor em um sistema com a capacidade limitada.

Fila M/M/1/B/FIFO



Sendo λ a taxa de chegada, a taxa efetiva então depende da probabilidade de o sistema estar repleto de usuários:

$$\lambda' = \lambda(1 - P_B)$$

A taxa efetiva de chegada λ' é a taxa de chegada original λ ajustada pela probabilidade de o sistema não estar cheio ($1 - P_B$), já que chegadas só podem entrar no sistema quando ele não está cheio.

Fila M/M/1/B/FIFO



Sendo λ a taxa de chegada, a taxa de perda λ_{perda} é a taxa na qual as requisições que chegam encontram o sistema completamente ocupado e, por isso, são perdidas ou bloqueadas. Ela se dá por:

$$\lambda_{perda} = \lambda P_B$$

Ao multiplicar a taxa de chegada λ pela probabilidade de o sistema estar ocupado P_B , obtemos a taxa média na qual os clientes chegam e são rejeitados, porque o sistema está cheio.

Fila M/M/1/B/FIFO



Medidas de Desempenho:

- Número médio de usuários no sistema:

$$E[n] = \frac{\rho}{1 - \rho} - \frac{(B + 1)\rho^{B+1}}{1 - \rho^{B+1}}$$

- Número médio de usuários na fila:

$$E[n_w] = \frac{\rho}{1 - \rho} - \rho \frac{1 + B\rho^B}{1 - \rho^{B+1}}$$

Fila M/M/1/B/FIFO



Continuação:

- Tempo médio de resposta:

$$E[s] = \frac{E[n]}{\lambda(1 - P_B)}$$

- Número médio de espera:

$$E[w] = \frac{E[n_w]}{\lambda(1 - P_B)}$$

Fila M/M/1/B/FIFO



Exemplo

Você é um administrador de sistemas encarregado de gerenciar um servidor que processa requisições de rede em um ambiente de computação. O servidor opera seguindo um modelo de fila M/M/1/B e você foi encarregado de analisar seu desempenho e capacidade.

Dados:

- Taxa de chegada (λ): 10 requisições por segundo;
- Taxa de serviço (μ): 12 requisições por segundo;
- Capacidade máxima do sistema (B): 5 requisições.

Calcule:

- Taxa de utilização do servidor (ρ);
- Taxa de utilização do sistema (U);
- Probabilidade de nenhuma requisição no sistema (P_0);
- Probabilidade do sistema descartar requisições (P_B);
- Taxa efetiva de chegada (λ');
- Taxa efetiva de perda (λ_{perda});

Fila M/M/1/B/FIFO



Exemplo

Continuação:

- Número médio de usuários no sistema ($E[\eta]$);
- Número médio de usuários na fila ($E[n_w]$);
- Tempo médio de resposta ($E[s]$);
- Tempo médio de espera ($E[w]$).



Fila M/M/1/B/FIFO

Exercício 1

Você está desenvolvendo um sistema distribuído e precisa decidir sobre o número de réplicas para um serviço específico. Para ajudar na decisão, você decide modelar o sistema como uma fila M/M/1/B para analisar o impacto da capacidade no desempenho. São dadas as seguintes informações:

- Taxa de chegada (λ): 15 requisições por segundo;
- Taxa de serviço (μ): 20 requisições por segundo;

Calcule:

- Calcule a taxa de utilização, a probabilidade de bloqueio e o número médio de requisições no sistema para $B=3$;
- Repita os cálculos para $B=5$;
- Com base nos resultados, discuta o impacto de aumentar a capacidade B no desempenho do serviço.



Fila M/M/1/B/FIFO

Exercício 2

Você está gerenciando um banco de dados que recebe consultas de vários clientes. O banco de dados pode ser modelado como um sistema de filas M/M/1/B, e você precisa garantir que a taxa de perda de consultas seja minimizada. São fornecidas as seguintes informações:

- Taxa de Chegada (λ): 7 consultas por segundo;
- Taxa de Serviço (μ): 10 consultas por segundo.

Calcule:

- Para $B = 4$, calcule a taxa de perda e a taxa de chegada efetiva;
- Suponha que você tem a opção de aumentar a taxa de serviço (μ) para 12 consultas por segundo. Recalcule a taxa de perda e a taxa de chegada efetiva. Discuta se vale a pena aumentar a taxa de serviço.

Fila M/M/1/B/FIFO



Exercício 3

Você é responsável por um servidor web que atende a várias requisições de usuários. O servidor pode ser modelado como um sistema de fila M/M/1/B. Os seguintes parâmetros são fornecidos:

- Taxa de Chegada (λ): 25 requisições por segundo;
- Taxa de Serviço (μ): 30 requisições por segundo;
- Capacidade Máxima do Sistema (B): 7 requisições.

Calcule:

- Calcule a taxa de utilização, a probabilidade de bloqueio, a taxa de perda, a taxa de chegada efetiva e o número médio de requisições no sistema.
- Como administrador do servidor, você está considerando a possibilidade de aumentar a capacidade do sistema para 10 requisições. Calcule os novos valores dos parâmetros de desempenho e discuta se o aumento de capacidade trará melhorias significativas.

Fila M/M/m/B/FIFO

Fila M/M/m/B/FIFO



Este tipo de fila é um sistema de perdas como Fila M/M/1/B, com a diferença de que em vez de um servidor, tem-se m servidores e uma capacidade limitada a B clientes.

Cada nova requisição que entra no sistema é alocada a um servidor, até que os servidores estejam ocupados. Após este limiar, toda nova requisição que chegar entrará na fila, até um limite de $B - m$ novos clientes.

A taxa de serviço é constante e a taxa de chegadas depende do número de requisições já recebidas e sendo processadas ou na fila, até o limite de B requisições.

$$\lambda_n = \begin{cases} \lambda, & \text{se } 0 \leq n < B \\ 0, & \text{se } n \geq B \end{cases}$$

$$\mu_n = \begin{cases} n\mu, & \text{se } 1 \leq n < B \\ m\mu, & \text{se } m \leq n \leq B \end{cases}$$



Fila M/M/m/B/FIFO

A probabilidade de n usuários no sistema se dá por:

$$P_n = \begin{cases} \frac{1}{n!} \left(\frac{\lambda}{\mu} \right)^n P_0, & \text{se } 1 \leq n < B - 1 \\ \frac{1}{m^{n-m} m!} \left(\frac{\lambda}{\mu} \right)^n P_0, & \text{se } m \leq n \leq B \end{cases}$$

A probabilidade de nenhum usuário no sistema se dá por:

$$P_0 = \begin{cases} \left[\sum_{n=0}^{m-1} \frac{1}{n!} \left(\frac{\lambda}{\mu} \right)^n + \left(\frac{\lambda}{\mu} \right)^m \frac{B-m+1}{m!} \right]^{-1}, & \text{se } \rho = \frac{\lambda}{m\mu} = 1 \\ \left[\sum_{n=0}^{m-1} \frac{1}{n!} \left(\frac{\lambda}{\mu} \right)^n + \left(\frac{\lambda}{\mu} \right)^m \frac{(1-\rho)^{B-m+1}}{m!(1-\rho)} \right]^{-1}, & \text{se } \rho = \frac{\lambda}{m\mu} \neq 1 \end{cases}$$

Fila M/M/m/B/FIFO



Sendo $\rho = \frac{\lambda}{m\mu}$, a taxa de utilização do sistema (U) se dá por:

$$U = \rho(1 - P_0)$$

Sendo λ a taxa de chegada, a taxa efetiva então depende da probabilidade de o sistema estar repleto de usuários:

$$\lambda' = \lambda(1 - P_B)$$

A taxa efetiva de chegada λ' é a taxa de chegada original λ ajustada pela probabilidade de o sistema não estar cheio ($1 - P_B$), já que chegadas só podem entrar no sistema quando ele não está cheio.

Fila M/M/m/B/FIFO



Sendo λ a taxa de chegada, a taxa de perda λ_{perda} é a taxa na qual as requisições que chegam encontram o sistema completamente ocupado e, por isso, são perdidas ou bloqueadas. Ela se dá por:

$$\lambda_{perda} = \lambda P_B$$

Ao multiplicar a taxa de chegada λ pela probabilidade de o sistema estar ocupado P_B , obtemos a taxa média na qual os clientes chegam e são rejeitados, porque o sistema está cheio.



Fila M/M/m/B/FIFO

Número médio de usuários no sistema:

$$E[n] = \sum_{n=1}^B nP_n$$

Número médio de usuários no sistema na fila:

$$E[n_w] = \sum_{n=m+1}^B (n - m)P_n$$

Tempo médio de resposta:

$$E[s] = \frac{[E_n]}{\lambda(1 - P_B)}$$

Tempo médio de espera:

$$E[w] = \frac{E[n_w]}{\lambda(1 - P_B)}$$

Fila M/M/m/B/FIFO



Exercício

Imagine um servidor web que processa solicitações de usuários. O servidor tem capacidade para processar simultaneamente quatro solicitações ($m = 4$). Há um limite no número de solicitações que podem ser colocadas em fila para processamento, que é de 10 solicitações ($B = 14$, incluindo as solicitações sendo processadas). As solicitações chegam seguindo um processo de Poisson com uma taxa média de $\lambda = 6$ solicitações por hora. Cada solicitação leva, em média, 10 minutos para ser processada (taxa de serviço $\mu = 6$ por hora). O sistema usa a disciplina de fila FIFO (First In, First Out).

Calcule:

- Calcule a probabilidade P_0 de que não haja solicitações no sistema;
- Determine a probabilidade de que exatamente 8 solicitações estejam no sistema (P_8);